

Enci/ VENTAS

Documentacion del Modulo RAG

Enci Chat - IA RAG con DeepSeek

Documento 16 - Arquitectura, uso, endpoints, controles y alcance de entrega parcial

Desarrollado por Grupo PLM - Universidad Tecnologica Metropolitana (UTEM)

Lider: Joshua Flores

Integrantes: Falon Berrios, Carolaine Palacios y Eliseo Poblete

Cliente / representante receptor: Max

Version 1.0 - Julio 2026

AMBITO	ESTADO	CRITERIO
IA RAG con DeepSeek	Parcialmente entregado	Chat documental operativo en su estado actual, condicionado a corpus, configuracion y proveedor externo.
Backend FastAPI	Implementado	Endpoints /rag protegidos por token Firebase y control de rol.
Carga documental	Administrada	Subida, validacion, indexacion y reindexacion restringidas a rol administrador.
Continuidad evolutiva	Fuera de alcance MVP	No incluye tuning, reentrenamiento, cambio de proveedor ni optimizacion avanzada.

Declaracion de alcance

El modulo RAG se documenta como componente parcialmente entregado y operativo en el estado actual. Su entrega no obliga a evolucion, entrenamiento adicional, cambio de proveedor, carga masiva de corpus ni soporte de calidad de respuesta fuera del alcance acordado.

Tabla de Contenidos

1. Introduccion
2. Alcance Funcional del Modulo
3. Arquitectura RAG
4. Flujo de Conversacion
5. Endpoints y Contratos
6. Variables de Entorno
7. Gestion Documental e Indexacion
8. Seguridad y Controles
9. Operacion, Validacion y Soporte
10. Limitaciones, Riesgos y Cierre

1. Introduccion

Enci Chat corresponde al modulo de asistencia documental y comercial incorporado al ecosistema Enci/ Ventas. Su objetivo es permitir que usuarios autenticados realicen consultas sobre informacion tecnica, comercial, documental y datos internos disponibles para el sistema, usando un flujo de recuperacion de contexto antes de generar una respuesta.

El modulo utiliza un enfoque RAG, es decir, Retrieval-Augmented Generation. En terminos operativos, la respuesta no se genera de forma aislada: primero se recuperan fragmentos relevantes desde documentos indexados y, cuando corresponde, desde datos internos del CRM. Luego ese contexto se entrega al proveedor LLM para producir una respuesta trazable y acotada al material disponible.

Principio de uso
El asistente debe entenderse como una herramienta de apoyo documental y comercial. Sus respuestas no reemplazan validacion humana, criterio tecnico, aprobacion comercial ni revision formal de fichas, politicas o documentos fuente.

1.1 Objetivo del documento

Este documento formaliza el funcionamiento, alcance, limites, dependencias, seguridad y operacion del modulo RAG entregado para Enci/ Ventas. Su finalidad es dejar evidencia tecnica para el cliente, facilitar soporte posterior y establecer criterios claros de aceptacion del componente parcial.

Objetivo	Descripcion
Documentar arquitectura	Explicar como el frontend, backend, Firestore, documentos indexados, Chroma y DeepSeek se relacionan dentro del flujo RAG.
Definir permisos	Precisar que usuarios pueden consultar, listar conversaciones o administrar documentos.
Definir contratos	Identificar endpoints, payloads principales, respuestas esperadas y restricciones.
Acotar el cierre	Establecer que la entrega corresponde al estado actual acordado y no a una plataforma IA completamente evolucionada.

1.2 Estado de entrega

Componente	Estado	Observacion
Chat RAG	Parcialmente entregado / operativo	Recibe pregunta, recupera contexto, responde y persiste conversacion.
Proveedor LLM	Configurado en backend	DeepSeek se consume desde backend mediante variable segura.
Corpus documental	Administrable	Soporta carga e indexacion de documentos definidos por administradores.
Datos internos	Disponible bajo seleccion de contexto	El backend puede construir fragmentos internos de CRM cuando la pregunta lo requiere.
Calidad de respuesta	Dependiente del corpus	La precision depende de documentos cargados, calidad del texto, parametros y disponibilidad del proveedor.

2. Alcance Funcional del Modulo

El modulo RAG cubre consultas conversacionales y documentales desde usuarios autorizados. Tambien incluye administracion basica de documentos para construir o reconstruir el indice semantico.

2.1 Capacidades incluidas

- Recepcion de preguntas desde usuarios autenticados mediante token Firebase.

- Sanitizacion de pregunta y validacion de largo maximo.
- Busqueda de fragmentos documentales similares usando indice semantico.
- Construccion de contexto interno cuando la pregunta apunta a datos comerciales o cuando no existe contexto documental suficiente.
- Invocacion de proveedor DeepSeek solo cuando existe contexto util para responder.
- Respuesta local controlada cuando no existe contexto suficiente.
- Persistencia de conversaciones por usuario en Firestore.
- Generacion o normalizacion de titulo de conversacion.
- Carga, validacion, almacenamiento e indexacion de documentos por administradores.
- Reindexacion completa de documentos activos por administradores.

2.2 Capacidades excluidas

Exclusion	Motivo de cierre
Reentrenamiento de modelo	El proveedor DeepSeek se consume como servicio externo; no se entrega entrenamiento propio.
Tuning avanzado de prompts	Queda fuera del MVP y requeriria iteraciones adicionales con medicion de calidad.
Cambio a Gemini, Vertex u otro proveedor	Corresponde a nueva estimacion, ajuste tecnico y validacion de arquitectura.
Carga masiva de corpus no controlada	El MVP exige validacion de archivo, formato, tamano y administracion controlada.
SLA de proveedor externo	La disponibilidad y latencia del proveedor LLM no depende del equipo de desarrollo.
Evaluacion estadistica de calidad IA	No se entrega benchmark formal de precision, recall, alucinacion o evaluacion humana sistematica.

3. Arquitectura RAG

La arquitectura separa claramente la interfaz de usuario, la autorizacion, la recuperacion de contexto, la generacion de respuesta y la persistencia de conversaciones. El frontend no contiene llaves de proveedor IA ni ejecuta logica de indexacion.

3.1 Componentes principales

Capa	Componente	Responsabilidad
Frontend web / app vendedor	Enci Chat	Captura pregunta, envia token Firebase y muestra respuesta, fuentes e historial disponible.
Backend API	FastAPI / router /rag	Valida token, rol, rate limit, pregunta y orquesta recuperacion y respuesta.
Autenticacion	Firebase Auth + Firebase Admin	Emite token en cliente y lo valida en backend antes de permitir operacion.
Persistencia	Cloud Firestore	Almacena conversaciones, documentos RAG y metadatos asociados.
Indice semantico	Chroma local persistido	Guarda chunks y embeddings para busqueda de similitud documental.
Proveedor LLM	DeepSeek	Genera respuesta final a partir del prompt del sistema, pregunta y contexto recuperado.
Almacenamiento documental	GCS o almacenamiento local segun configuracion	Conserva documentos cargados y sus metadatos para trazabilidad.

3.2 Diagrama logico textual

```

Usuario autenticado
-> Frontend Enci Chat
-> POST /rag/chat con Authorization: Bearer <firebase_id_token>
-> FastAPI valida token, rol y limite por usuario
-> Sanitiza pregunta
-> Busca chunks documentales en Chroma
-> Complementa con contexto interno si corresponde
-> Selecciona contexto final
-> DeepSeek genera respuesta cuando existe contexto
-> Motor local responde cuando no hay contexto suficiente
-> Firestore guarda turno de conversacion
-> API retorna respuesta, fuentes, tokens, timestamp y conversacion_id

```

4. Flujo de Conversacion

El flujo conversacional se ejecuta en una secuencia controlada. Cada solicitud pasa por controles de identidad, rol, limpieza de entrada, recuperacion y persistencia.

4.1 Secuencia operativa

- 1 El usuario ingresa a Enci Chat desde una interfaz autorizada.
- 2 El cliente obtiene el ID Token de Firebase y lo adjunta como Bearer token.
- 3 El backend valida el token y recupera el usuario desde Firestore.
- 4 El sistema valida que el usuario tenga rol habilitado y acceso a la plataforma correspondiente.
- 5 La pregunta se sanitiza y se rechaza si queda vacia o incumple las reglas de entrada.
- 6 Se aplica rate limit por uid para prevenir abuso o consumo excesivo.
- 7 Se decide si la pregunta es conversacional, documental o relacionada con datos internos.
- 8 Se recuperan fragmentos documentales e internos, se selecciona el contexto final y se invoca DeepSeek si corresponde.
- 9 La respuesta se construye con fuentes cuando existen fragmentos utilizados.
- 10 El turno queda persistido en Firestore dentro de la conversacion asociada.

4.2 Respuesta sin contexto suficiente

Cuando la busqueda no recupera contexto confiable para contestar, el sistema evita invocar el proveedor externo y responde localmente con un mensaje de alcance. Esto reduce costo, evita respuestas no fundadas y mantiene al asistente dentro de su dominio documental y comercial.

```

{
  "respuesta": "Este asistente esta enfocado en consultas tecnicas, comerciales, documentales y datos internos de l",
  "fuentes": [],
  "tokens_usados": 0
}

```

5. Endpoints y Contratos

Todos los endpoints del modulo RAG requieren autenticacion con Bearer token de Firebase. La autorizacion se aplica desde backend y no desde la visibilidad del frontend.

5.1 Matriz de endpoints

Metodo	Endpoint	Rol minimo	Uso principal
POST	/rag/chat	vendedor	Enviar pregunta al asistente RAG y recibir respuesta trazable.
GET	/rag/conversations	vendedor	Listar conversaciones visibles segun alcance de rol.
POST	/rag/documents/upload	admin	Cargar, validar, almacenar e indexar un documento.
POST	/rag/documents/reindex	admin	Reconstruir indice semantico desde documentos activos.
GET	/rag/documents	admin	Listar documentos disponibles dentro del corpus RAG.

5.2 POST /rag/chat

Recibe una pregunta del usuario autenticado y devuelve una respuesta con trazabilidad. El endpoint acepta una conversacion existente o crea una nueva cuando no se entrega conversacion_id.

Campo	Tipo	Regla
pregunta	string	Obligatoria. Largo entre 1 y 1000 caracteres. Se limpia antes de procesar.
conversacion_id	string opcional	Permite continuar una conversacion existente. Maximo 128 caracteres.

```
Solicitud:
{
  "pregunta": "Cual es la dosificacion del producto X para cerdos?",
  "conversacion_id": "uuid-opcional"
}

Respuesta esperada:
{
  "respuesta": "Segun la ficha tecnica...",
  "fuentes": [
    {"documento": "ficha_tecnica_productoX.pdf", "pagina": 3, "fragmento": "Texto usado como evidencia"}
  ],
  "conversacion_id": "uuid",
  "tokens_usados": 512,
  "timestamp": "2026-06-17T23:00:00Z"
}
```

5.3 Administracion documental

Endpoint	Entrada	Salida / efecto
/rag/documents/upload	multipart/form-data con campo file	Documento validado, almacenado, registrado e indexado.
/rag/documents/reindex	Sin cuerpo obligatorio	Reconstruccion del indice y cantidad de chunks indexados.
/rag/documents	Sin cuerpo	Listado de documentos registrados con metadatos publicos.

6. Variables de Entorno

Las variables RAG se configuran exclusivamente en backend. Ninguna llave de proveedor IA debe estar disponible en frontend ni en variables VITE_*

Variable	Uso	Criterio
DEEPSEEK_API_KEY	Llave de proveedor DeepSeek	Solo backend. Obligatoria para invocar proveedor externo.
DEEPSEEK_BASE_URL	URL base del proveedor	Valor esperado: https://api.deepseek.com.
DEEPSEEK_MODEL	Modelo usado para generacion	Valor documentado: deepseek-chat.
MAX_TOKENS_RESPONSE	Limite de tokens de respuesta	Controla longitud maxima solicitada al proveedor.
MAX_CONTEXT_CHUNKS	Cantidad maxima de fragmentos de contexto	Evita prompts excesivos y reduce ruido documental.
SIMILARITY_THRESHOLD	Umbral de similitud	Filtra fragmentos con baja pertinencia.

Variable	Uso	Criterio
CHROMA_PERSIST_DIR	Ruta de indice vectorial	Directorio local persistido para Chroma.
GCS_BUCKET_DOCUMENTS	Bucket documental	Usado cuando existe almacenamiento GCS habilitado.
LOCAL_DOCUMENT_STORAGE_DIR	Respaldo local documental	Ruta local cuando aplica almacenamiento local.
RAG_CHAT_RATE_LIMIT_PER_MINUTE	Limite de consultas por minuto	Valor base documentado: 30 por uid.
RAG_MAX_UPLOAD_BYTES	Tamano maximo de carga	Valor base documentado: 20 MB.

Control de secretos

DEEPSEEK_API_KEY y credenciales de almacenamiento no deben versionarse en GitHub, exponerse en frontend ni compartirse en capturas. Cualquier rotacion de secretos debe ejecutarse desde el panel del proveedor y el ambiente de despliegue.

7. Gestion Documental e Indexacion

El corpus documental constituye la base de conocimiento recuperable del asistente. La calidad de las respuestas depende directamente de la calidad, vigencia, estructura y pertinencia de los documentos cargados.

7.1 Formatos aceptados

Formato	Condicion	Uso esperado
PDF	Extension .pdf y contenido valido	Fichas tecnicas, manuales, catalogos o documentos comerciales.
DOCX	Extension .docx y estructura legible	Documentacion editable, guias o informes internos.
TXT	Texto UTF-8	Corpus liviano, extractos controlados o material de prueba.

7.2 Validaciones aplicadas

- Verificacion de extension y contenido real del archivo.
- Lectura de bytes bajo limite maximo permitido.
- Sanitizacion del nombre antes de guardar.
- Extraccion de texto desde el documento.
- Division del contenido en chunks recuperables.
- Generacion de embeddings con sentence-transformers.
- Persistencia de chunks en Chroma.
- Registro documental en Firestore con metadatos de auditoria.

7.3 Reindexacion

La reindexacion reconstruye el indice semantico desde documentos activos almacenados. Debe ejecutarse despues de cambios relevantes en corpus, restauraciones, migraciones o correcciones de almacenamiento.

Situacion	Accion recomendada
Documento cargado correctamente	No se requiere reindexacion global si la carga ya indexo sus chunks.
Indice local eliminado o inconsistente	Ejecutar POST /rag/documents/reindex desde usuario admin.

Situacion	Accion recomendada
Cambio de documentos activos	Reindexar para reconstruir busqueda semantica.
Cambio de modelo de embeddings	Reindexar todo el corpus; se considera cambio tecnico fuera del MVP base.

8. Seguridad y Controles

El modulo incorpora controles preventivos para identidad, autorizacion, abuso de uso, exposicion de secretos y administracion de corpus.

Control	Implementacion	Resultado esperado
Autenticacion	Authorization: Bearer	Sin token valido no hay acceso a endpoints RAG.
Roles	require_role(vendedor/admin)	Chat disponible para roles habilitados; documentos solo admin.
Rate limit	Control por uid	Reduce abuso, consumo accidental o rafagas.
Input	Pregunta sanitizada y limitada	No procesa preguntas vacias o fuera de largo permitido.
Archivos	Validacion de tipo, firma y tamaño	Rechaza cargas invalidas o excesivas.
Secretos	API key solo en backend	No expone credenciales en frontend ni VITE_*.
Fallback local	Respuesta sin proveedor cuando no hay contexto	Evita generar respuestas no sustentadas y reduce consumo.
Persistencia	Conversaciones en Firestore	Historial visible segun rol y cuenta.

8.1 Visibilidad de conversaciones

Rol	Visibilidad esperada
Vendedor	Accede a sus propias conversaciones e historial asociado a su cuenta.
Supervisor	Puede consultar consolidado segun alcance operativo definido por backend.
Admin	Puede consultar consolidado y administrar corpus documental.
Sin acceso / inactivo	No debe operar Enci Chat ni endpoints protegidos.

9. Operacion, Validacion y Soporte

La operacion del modulo RAG debe ejecutarse de forma controlada, especialmente por su dependencia de credenciales, proveedor externo, corpus documental y almacenamiento.

9.1 Checklist operativo

Revision	Comando o accion	Esperado
Backend activo	GET /health	status=ok.
Readiness	GET /readiness	status=ready o detalle de checks pendientes.
Swagger controlado	GET /docs en ambiente no productivo	Consola carga y permite login Google.
Chat RAG	POST /rag/chat	Respuesta con conversacion_id y timestamp.
Documentos	GET /rag/documents con admin	Listado de documentos registrados.
Carga documental	POST /rag/documents/upload	Mensaje de documento indexado exitosamente.
Reindexacion	POST /rag/documents/reindex	Retorna cantidad de chunks indexados.

9.2 Criterios de aceptacion tecnica

ID	Criterio	Aceptacion
RAG-01	Usuario autenticado consulta /rag/chat	La API responde con texto, timestamp y conversacion_id.
RAG-02	Pregunta vacia o invalida	La API rechaza con error controlado.
RAG-03	Consulta sin contexto suficiente	Se entrega respuesta local sin fuentes y sin invocacion innecesaria.
RAG-04	Documento valido cargado por admin	El documento se registra, se indexa y queda disponible para busqueda.
RAG-05	Documento invalido o excesivo	La API rechaza la carga con error claro.
RAG-06	Usuario no admin intenta administrar corpus	La API bloquea la accion con 403.
RAG-07	API key ausente	Readiness o ejecucion debe reflejar configuracion incompleta.

9.3 Guia de soporte inicial

Sintoma	Causa probable	Accion
El chat no responde	Backend caido, token invalido o proveedor no disponible	Validar /health, sesion Firebase, logs backend y configuracion DeepSeek.
Responde sin fuentes	No hay contexto recuperado o pregunta fuera de alcance	Revisar documentos cargados, reindexar corpus o reformular pregunta.
Error al cargar documento	Formato, tamano, extension o contenido invalido	Validar que sea PDF, DOCX o TXT UTF-8 y que no supere 20 MB.
Administrador no puede cargar	Rol no actualizado o token antiguo	Confirmar rol admin en Firestore, cerrar sesion e ingresar nuevamente.
Respuesta poco precisa	Corpus insuficiente, ambiguo o desactualizado	Cargar documentos fuente correctos y reindexar. Mejoras de calidad quedan como fase posterior.

10. Limitaciones, Riesgos y Cierre

El modulo RAG queda entregado como componente parcial y operativo, sujeto al estado del corpus, la configuracion del ambiente y la disponibilidad del proveedor externo.

10.1 Limitaciones aceptadas

- La respuesta depende de la calidad y completitud de los documentos cargados.
- El sistema no garantiza exactitud absoluta ni reemplaza revision humana.
- El proveedor DeepSeek puede tener latencia, errores o cambios fuera del control del equipo.
- No se incluye evaluacion formal de precision del modelo ni benchmark de calidad.
- No se incluye migracion de proveedor ni integracion con servicios IA corporativos distintos.
- No se incluye carga masiva ni gobierno documental avanzado.
- No se incluye mantenimiento evolutivo ni soporte post-entrega fuera de acuerdo adicional.

10.2 Riesgos residuales

Riesgo	Impacto	Mitigacion documentada
Corpus incompleto	Respuesta incompleta o sin fuentes	Cargar documentos correctos y reindexar.
Documento desactualizado	Respuesta basada en informacion antigua	Gobernanza documental y revision de vigencia por cliente.
Proveedor externo no disponible	Chat no puede generar respuesta LLM	Fallback local cuando no hay contexto; revisar proveedor y credenciales.

Riesgo	Impacto	Mitigacion documentada
API key expuesta accidentalmente	Riesgo de consumo indebido	Mantener llave solo backend y rotarla ante incidente.
Consulta fuera de dominio	Respuesta limitada o negativa	Mantener respuesta de alcance y fuentes controladas.

10.3 Cierre formal del componente

Criterio de cierre
El modulo Enci Chat / IA RAG se considera documentado y entregado parcialmente en el estado actual: endpoints disponibles, proveedor DeepSeek configurado en backend, carga documental administrable, conversaciones persistidas y controles basicos aplicados. Cualquier extension, mejora de precision, cambio de proveedor, tuning o mantenimiento posterior debe tratarse como nuevo requerimiento, nueva estimacion o Fase 2.

La aceptacion del modulo debe realizarse considerando su naturaleza parcial. Las limitaciones expresamente documentadas no deben clasificarse como bug del MVP principal, salvo que impidan operar las capacidades comprometidas dentro del alcance descrito.